

Pré-Projeto de Dissertação:

Estimação eficiente de vetores autoregressivos com parâmetros variando no tempo e volatilidade estocástica

Aishameriane Schmidt*

Outubro de 2017

Resumo

A proposta deste trabalho é combinar o modelo de volatilidade estocástica como proposto por Philipov e Glickman (2006b, 2006a) em um modelo de vetores autoregressivos com coeficientes variando no tempo. Serão desenvolvidos métodos para inferência do modelo utilizando amostragem por importância eficiente combinada com Rao-Blackwellização. Por fim, será feita uma aplicação com dados da economia brasileira.

Introdução

O modelo de vetores autoregressivos (VAR) foi desenvolvido na década de 70 por Christopher Sims e consiste em um conjunto de equações que permite modelar de maneira simultânea a dinâmica de um conjunto de séries temporais (DEL NEGRO; SCHORFHEIDE, 2013). Evidências de que os parâmetros de modelos VAR com dados macroeconômicos devem ser variantes no tempo (chamados de TVP-VAR) podem ser encontradas em diversos trabalhos, como por exemplo no artigo de Cogley e Sargent (2001), que utilizaram um TVP-VAR para verificar se houveram mudanças de comportamento da autoridade econômica em resposta aos choques na economia americana no período de 1948 a 2000. Incorporar características variantes no tempo nos modelos, do ponto de vista econômico, está em concordância com a Crítica de Lucas (LUCAS, 1976). Em seu artigo, Lucas criticou a invariância temporal subjacente aos modelos econométricos existentes na época, dado que empiricamente não é razoável esperar que as relações entre variáveis econômicas sejam estáveis ao longo de muitos anos, uma vez que os agentes respondem às mudanças de política e ou a choques e isso pode levar a mudanças nas escolhas ótimas.

Embora os modelos TVP-VAR sejam uma alternativa para investigar possíveis mudanças ocorridas na estrutura do modelo, decorrentes, por exemplo, de mudanças na política, estes modelos originalmente não capturavam mudanças temporais na variância

*Contato: aishameriane.schmidt@posgrad.ufsc.br

Pré-projeto entregue para a disciplina de Seminários de Dissertação em 2017/2 - Prof. Dr. Jaylson da Silveira. Prof. Orientador: Guilherme Valle Moura.

dos dados. Neste sentido, Sims (2001) e Stock (2001) criticaram o trabalho de Cogley e Sargent (2001) argumentando que o modelo poderia estar mal especificado por não conter uma componente de volatilidade estocástica multivariada (MSV). Isso faz com que toda a variação no tempo ocorresse apenas nas componentes de persistência, de maneira que eventuais variações na volatilidade poderiam passar despercebidas. Em um trabalho posterior, Cogley e Sargent (2005) incorporaram a componente de volatilidade estocástica ao seu modelo original, ao encontro da crítica feita por Sims e Stock. Os resultados encontrados anteriormente, de mudanças nos parâmetros, foram confirmados e a explicação é de que eles refletem as mudanças de crença da autoridade monetária. Além disso, foram observadas alterações na volatilidade dos choques, que, de acordo com os autores, estariam refletindo os efeitos de choques de variáveis exógenas na economia.

Outros trabalhos na área de macroeconomia que mesclam TVP-VAR com uma componente de volatilidade estocástica foram desenvolvidos ao longo dos últimos anos. Por exemplo, o artigo de Mumtaz e Zanetti (2015) utiliza o modelo para verificar mudanças no padrão de procura por emprego e taxa de separação no mercado de trabalho; Baumeister e Peersman (2013) fizeram a modelagem da resposta da economia a choques na oferta de petróleo nos EUA e Galí e Gambetti (2015) estudaram o efeito de política monetária em bolhas no mercado financeiro .

Apesar dos modelos TVP-VAR serem ferramentas úteis para previsão e descrição de dados macroeconômicos, não há um consenso sobre a forma mais eficiente de obter as estimativas e realizar diagnósticos. Na próxima seção alguns dos problemas com relação à estimação e diagnóstico de modelos existentes serão levantados e será apresentada uma proposta de modelo TVP-VAR com MSV Wishart. Também será introduzido o método de amostragem por importância, que poderá ser utilizado no modelo proposto para obter melhores estimativas.

1 Referencial teórico

1.1 Modelos TVP-VAR com volatilidade estocástica multivariada

Um modelo TVP-VAR pode ser representado por um modelo de espaço de estados da seguinte forma:

$$y_t = Z_t \alpha_t + \epsilon_t \quad \epsilon_t \sim \mathcal{N}_k(\mathbf{0}_k, \Omega_t^{-1}) \quad (\text{eq. de medida}) \quad (1)$$

$$\alpha_t = \alpha_{t-1} + u_t \quad u_t \sim \mathcal{N}_p(\mathbf{0}_p, Q) \quad (\text{eq. de transição dos estados}), \quad (2)$$

onde:

- y_t é um vetor de dimensão $k \times 1$ de variáveis endógenas observadas no instante t ;
- Z_t é uma matriz com os valores defasados de y_t de forma que $Z_t = \mathbb{I}_k \otimes [1, y'_{t-1}, \dots, y'_{t-\ell}]$, onde \otimes denota o produto de Kronecker e \mathbb{I}_k é a matriz identidade de dimensão k ;
- α_t é um vetor com $p = k(\ell + 1)$ coeficientes que variam no tempo de acordo com a equação de estados (e seriam estáticos em um modelo cujos parâmetros não variam no tempo);
- Ω_t^{-1} e Q são matrizes de covariância com dimensão $k \times k$ e $p \times p$, respectivamente, sendo que Ω_t^{-1} é estocástica.

As equações (1) e (2) definem um sistema dinâmico formado por uma equação de medida, cuja estrutura é similar a um modelo de regressão com a variável independente α_t , e uma equação de transição dos estados, que descreve a trajetória do sistema através de um modelo autoregressivo. Os estados α_t são chamados de variáveis *latentes* uma vez que apenas as medidas y_t podem ser observadas. Para estimativa dos estados latentes de um sistema dinâmico pode-se fazer uso de métodos de filtragem, que irão utilizar a sequência das medidas y_t para realizar inferência a respeito dos estados α_t (DURBIN; KOOPMAN, 2012). + Intuitivamente, o processo de filtragem consiste em um método recursivo com duas etapas: **previsão** e **atualização**. Em um primeiro momento, todas as informações disponíveis são utilizadas para fazer a melhor previsão possível do sistema. Assim que novas observações de y estão disponíveis, a previsão é atualizada, utilizando a fórmula de Bayes.

Formalmente, deseja-se obter uma estimativa para o estado α dado a observação medida y_t , isto é, deseja-se estimar $p(\alpha_t)$. Por exemplo, para $t = 1$, tem-se:

$$p(\alpha_1|y_1) = \frac{p(y_1|\alpha_1)p(\alpha_1)}{p(y_1)}. \quad (3)$$

Nos os passos seguintes, o termo $p(\alpha_1)$ de (3) será do tipo $p(\alpha_t|y_{t-1})$, que pode ser obtido da seguinte forma:

$$p(\alpha_t|y_{t-1}) = \int p(\alpha_t|\alpha_1)p(\alpha_1|y_1)d\alpha_1. \quad (4)$$

Pode-se obter uma equação para $p(\alpha_t)$ combinando (4) com o teorema de Bayes:

$$p(\alpha_1|y_1) = \frac{p(y_t|\alpha_t)p(\alpha_t|y_{t-1})}{p(y_t|y_{t-1})}, \quad (5)$$

onde o termo $p(y_t|y_{t-1}) = \int p(y_t|\alpha_t)p(\alpha_t|y_{t-1})d\alpha_t$ fornece a contribuição da observação t para a verossimilhança da amostra toda. Quando o modelo é linear e gaussiano, o processo de filtragem possui fórmulas analíticas fechadas e é chamado de Filtro de Kalman. Entretanto, não se pode utilizar o filtro de Kalman no sistema (1)-(2), pois a matriz Ω_t^{-1} é estocástica (e possivelmente o sistema não será gaussiano).

Cogley e Sargent (2005) propõem um amostrador de Gibbs para obter as estimativas a posteriori do seu modelo. Porém, a sua especificação da matriz de inovações Ω_t^{-1} implica que os choques de uma variável em outras são invariantes no tempo, isto é, os elementos da matriz de covariâncias são fixos. Isto foi criticado por Primiceri (2005), que argumentou que as interações simultâneas entre variáveis são essenciais para captar os efeitos de variação no tempo neste tipo de modelo.

No trabalho de Primiceri (2005) as covariâncias entre variáveis seguem um passeio aleatório, dando mais flexibilidade ao modelo. Entretanto, este modelo não é invariante à ordem das variáveis no sentido de que a solução das estimativas não é única para um mesmo conjunto de dados. Esta característica tem sua gênese na forma como é imposta a dinâmica da volatilidade estocástica (PRIMICERI, 2005).

Philipov e Glickman (2006b, 2006a) trabalham com um modelo de MSV cuja especificação para Ω_t é uma densidade Wishart de dimensão k com $\nu > k$ graus de

liberdade:

$$\Omega_t | \Omega_{t-1} \sim \mathcal{W}_k(\nu, S_{t-1}). \quad (6)$$

A matriz de precisão S_{t-1} é um processo estocástico com equação de transição dada por:

$$S_t = \frac{1}{\nu} A^{1/2} \Omega_t^d A^{1/2'}. \quad (7)$$

onde A é uma matriz simétrica positiva definida que contém os parâmetros que definem a sensibilidade temporal dos elementos de S_t e d é um parâmetro que determina a persistência do processo. Um modelo de MSV como (6)-(7) permite tanto que as covariâncias entre as variáveis sejam variantes no tempo como também não sofre do problema de invariância que o TVP-VAR de Primiceri (2005). Mas, assim como os modelos de Primiceri (2005) e Cogley e Sargent (2005), o modelo de Philipov e Glickman (2006b, 2006a) também é um modelo de estado de espaços não linear e não gaussiano com uma verossimilhança que não pode ser tratada analiticamente. Para resolver o problema de estimação do modelo, Philipov e Glickman (2006a) e Asai, McAleer e Yu (2006) utilizam abordagem bayesiana com uso de amostradores de Gibbs. No entanto, Philipov e Glickman (2006a) descrevem problemas para estimar adequadamente o parâmetro d de persistência e foi preciso fixá-lo a priori; já no trabalho de Asai e McAleer (2009) foram relatados problemas de ineficiência, possivelmente relacionados com a convergência do amostrador de Gibbs.

Uma vez que a característica indesejável de não invariância do modelo de Primiceri (2005) está relacionada com a estrutura da volatilidade, poderia-se tentar contornar o problema combinar o modelo TVP-VAR dado em (1)-(2) com o modelo MSVW (6)-(7) obtendo a seguinte forma funcional:

$$y_t = Z_t \alpha_t + \epsilon_t, \quad \epsilon_t \sim \mathcal{N}_k(\mathbf{0}_k, \Omega_t^{-1}) \quad (8)$$

$$\alpha_t = \alpha_{t-1} + u_t, \quad u_t \sim \mathcal{N}_p(\mathbf{0}_p, Q) \quad (9)$$

$$\Omega_t | \Omega_{t-1} \sim \mathcal{W}_k \left(\nu, \frac{1}{\nu} A^{1/2} \Omega_{t-1}^d A^{1/2'} \right). \quad (10)$$

Dado que a matriz Ω_t entra na equação de medida (8) como a componente de variância e segue uma distribuição Wishart multivariada, o sistema das equações (8)-(10) também é um modelo de espaço de estados não linear e não gaussiano. A função de verossimilhança é obtida integrando a densidade conjunta de y_t , Ω_t e α_t com relação às componentes de estado não observáveis, α_T e Ω_T :

$$L_\theta = \int \int \prod_{t=1}^T g_\theta(y_t | \Omega_t, \alpha_t) p_\theta(\alpha_t | \alpha_{t-1}) p_\theta(\Omega_t | \Omega_{t-1}) d\alpha_T d\Omega_T, \quad (11)$$

onde $p_\theta(\alpha_t | \alpha_{t-1})$ está relacionada com a equação de transição (9) e, portanto, é um processo gaussiano e as variáveis com índice T representam uma sequência que vai de $j = 1$ a t .

Observe que, para cada sequência específica de matrizes Ω_T , o sistema formado pelas equações (8) e (9) é um sistema linear gaussiano, permitindo o uso do Filtro de

Kalman para a verossimilhança condicional dado Ω_T . Com isso, pode-se resolver a integral em relação a α_T de (11) simplificando o problema para:

$$L_\theta = \int \prod_{t=1}^T g_\theta(y_t|y_{t-1}, \Omega_t) p_\theta(\Omega_t|\Omega_{t-1}) d\Omega_T. \quad (12)$$

A densidade $g_\theta(y_t|y_{t-1}, \Omega_t)$ é obtida via filtro de Kalman e representa a contribuição da verossimilhança condicional avaliada no período t , dado Ω_t .

O procedimento acima, de marginalização de variáveis que são condicionalmente lineares, é chamado de Rao-Blackwellização (RB) e possibilita diminuir dimensão do problema de integração. O teorema de Rao-Blackwell, que empresta o nome ao método, garante que a variância das estimativas obtidas em (12) será menor ou igual às obtidas em (11). Moura e Turatti (2014) fazem uma aplicação de RB combinada com EIS para modelos com volatilidade estocástica, enquanto que Bognanni (2016) utiliza RB para obter as estimativas bayesianas em um modelo VAR com MSV Wishart.

A não linearidade dos problemas envolvendo volatilidade estocástica implica que a função de verossimilhança depende de integrais de dimensões altas, o que se torna computacionalmente desafiador e pode levar a estimação ineficiente do ponto de vista estatístico. A verossimilhança em (12) pode ser avaliada de diferentes maneiras, sendo que a proposta deste trabalho é fazer uso de amostragem por importância eficiente, que é introduzido na próxima seção.

1.2 Amostragem por Importância

Métodos de Monte Carlo (MC) são procedimentos de integração estocástica que foram desenvolvidos para aproximar soluções de integrais cuja solução analítica é inexistente ou é muito complexa para resolver com métodos numéricos tradicionais. Especificamente, os métodos de Monte Carlo utilizam o teorema do limite central e a lei dos grandes números para utilizar uma média amostral com o intuito de aproximar uma esperança populacional.

Considere, por exemplo, a seguinte integral:

$$I = \int_{\mathcal{X}} g(x) f(x) dx. \quad (13)$$

Se x for um vetor aleatório com função densidade de probabilidade (f.d.p.) dada por $f(\cdot)$, então a equação (13) pode ser vista como a esperança da função $g(\cdot)$ aplicada à variável aleatória X , isto é:

$$I = \mathbb{E}_f[g(x)]. \quad (14)$$

Caso seja possível retirar amostras aleatórias da densidade f_X , pode-se aproximar (14) (e, portanto, (13)) por uma média amostral:

$$I \approx \frac{1}{N} \sum_{i=1}^N g(x_i). \quad (15)$$

Sob condições de regularidade, a lei forte dos grandes números garante que (15) converge quase certamente para (14) (GEWEKE, 1989). Implementar requer (15) o uso de

um gerador de números pseudo-aleatórios que gere amostras de uma densidade uniforme e para então simular dados de $f(\cdot)$. Porém, em muitas situações não é possível amostrar da densidade f seja porque sua forma é desconhecida, seja porque o suporte comum entre f e g é pequeno, de forma que outros métodos para avaliar (13) são necessários.

Mesmo naquelas aplicações onde os problemas acima relatados não ocorrem, métodos de MC usados para resolver integrais como (13) não impõem restrições na relação entre as funções f e g , entretanto é possível que muitos valores amostrados da densidade f_X estejam fora do domínio de $g(\cdot)$, aumentando a variância das estimativas calculadas. Amostragem por importância (IS) é um método de Monte Carlo que busca melhorar o processo de amostragem para reduzir a variância gerada pela falta de suporte comum entre $f(x)$ e $g(x)$. Para isso, é escolhida uma densidade auxiliar, chamada de *amostrador por importância*, que permite concentrar os valores amostrados em uma região contendo mais valores na interseção com o domínio de $g(x)$.

A expressão (13) pode ser reescrita como:

$$I = \int_{\mathcal{X}} g(x) \frac{f(x)}{m(x)} m(x) dx = \mathbb{E}_m \left[\frac{g(x)f(x)}{m(x)} \right]. \quad (16)$$

Da mesma maneira que os métodos de Monte Carlo clássicos, a expressão (16) pode ser aproximada por uma média amostral:

$$I \approx I_{IS}^N = \frac{1}{N} \sum_{i=1}^N \omega(x_i) g(x_i), \quad (17)$$

onde $\omega_i = \frac{f(x_i)}{m(x_i)}$ são os chamados *pesos de importância* e x_i são amostrados da densidade m . A vantagem da amostragem por importância em relação aos métodos de Monte Carlo usuais é, usando a ponderação com os pesos ω_i , corrigir o viés de amostrar valores da $f(\cdot)$ que estariam muito distantes da região de importância onde $g(\cdot)$ está concentrada. Assim como (15), a expressão (17) também converge para (13), se algumas hipóteses de regularidade forem atendidas. Utilizando o fato de que I_{IS}^N é um estimador não viesado para I , variância de (17) será dada por:

$$\sigma_{IS}^2 = \int g^2(x) \frac{f^2(x)}{m(x)} dx - I^2. \quad (18)$$

É importante observar que para haver convergência do estimador de importância, é necessário que $\int g^2(x) \frac{f^2(x)}{m(x)} dx < \infty$. Isso não ocorre para os casos onde as caudas da densidade $m(x)$ são mais leves do que as de $f(x)$ e daí a relevância de escolher um estimador por importância apropriado que faça com que (18) esteja bem definida. Mais detalhes sobre amostragem por importância podem ser encontrados em Moura (2010), Robert e Casella (2010) e Durbin e Koopman (2012).

Embora (17) deva convergir para para todas as funções que satisfazem a condição do suporte comum, a escolha a função de importância é crucial por duas principais razões. Além de ser necessário que a simulação dos valores da densidade m seja de fácil implementação; é preciso também que $m(x)$ seja próxima o suficiente de $f(x)g(x)$ de maneira a reduzir a variabilidade de (17). Se isso não ocorrer, os pesos $\omega(x_i)$ serão demasiadamente pequenos e poucas observações serão de fato relevantes. Além disso, corre-se o risco de $E_m[g^2(x)f(x)\omega(x)]$ não ser finito e a variância do estimador em (17) não estar definida.

Uma das principais dificuldades ao utilizar amostragem por importância é encontrar um amostrador que seja “bom”, no sentido de reduzir a variância das estimativas de Monte Carlo. Especificamente, existem dois problemas centrais ao se trabalhar com IS: (a) a escolha da classe M de estimadores paramétricos e (b) a seleção dos parâmetros que definem um estimador em M que minimizem a variância das estimativas obtidas (MOURA, 2010). A *amostragem por importância eficiente* (EIS) é um método genérico que busca dentro de uma classe de densidades paramétricas a melhor aproximação global para o produto $g(x)f(x)$ em (16).

Assumindo que se tenha escolhido uma classe paramétrica de estimadores $M : \{m(x; a); a \in \mathcal{A}\}$, onde \mathcal{A} denota o espaço de parâmetros, o objetivo do algoritmo de EIS é encontrar o valor ótimo a^* para o qual a variância de (17) é mínima. Por exemplo, para um problema de dimensão baixa a ser resolvido com EIS, o produto $f(x)g(x)$ é aproximado pelo núcleo $k(x, a)$, $a \in (A)$, cuja relação com a densidade por importância é dada por:

$$m(x; a) = \frac{k(x; a)}{\chi(a)}, \quad (19)$$

onde $\chi(a) = \int_X k(x; a)dx$ é a constante de integração.

É possível mostrar que o um valor quase ótimo para a pode ser encontrado resolvendo um problema de mínimos quadrados da seguinte forma:

$$(\hat{a}, \hat{\gamma}) = \arg \min_{a \in \mathcal{A}, \gamma \in \mathbb{R}} q(x, a) \quad (20)$$

$$q(x, a) = \int_{\chi} d^2(x; a) \cdot \omega(x, a) \cdot m(x, a) dx, \quad (21)$$

com

$$d(x, a) = \ln f(x)g(x) - \gamma - \ln k(x, a), \quad (22)$$

$$w(x, a) = \frac{f(x)g(x)}{m(x, a)}. \quad (23)$$

onde a constante γ será tratada como um intercepto desconhecido no problema de otimização apresentado.

O algoritmo de EIS envolve fazer a estimativa de Monte Carlo para $q(x, a)$, porém, uma vez que o amostrador por importância depende de a , essa solução não é direta. A proposta de Richard e Zhang (2007) é de implementar um método recursivo onde uma sequência de estimadores $\{m(x, \hat{a}_j)\}_{j=0}^*$ que convirja para $m(x, a^*)$ é construída.

Para um dado $\hat{a}_j \in \mathcal{A}$, uma estimativa de MC para (21) é:

$$\bar{q}_N(a|\hat{a}_j) = \frac{1}{N} \sum_{i=1}^N \underbrace{\left[\ln f(\tilde{x}_i^j)g(\tilde{x}_i^j) - \gamma - \ln k(\tilde{x}_i^j, a_j) \right]^2}_{d(\tilde{x}_i^j, \hat{a}_j)^2} \cdot w(\tilde{x}_i^j, \hat{a}_j). \quad (24)$$

Os valores $\{\tilde{x}_i^j\}_{i=1}^N$ são amostrados de $m(x, \hat{a}_j)$. O problema se torna, então, um problema recursivo da forma:

$$(\hat{a}_{j+1}, \hat{\gamma}_{j+1}) \arg \min_{a \in \mathcal{A}, \gamma \in \mathbb{R}} \bar{q}_N(a | \hat{a}_j). \quad (25)$$

Com $\bar{q}_N(a | \hat{a}_j)$ definido em (24).

Richard e Zhang (2007) sugerem que utilizar os valores iniciais dos pesos $\omega(\cdot)$ em (24) iguais a 1 evita possíveis instabilidades numéricas do procedimento de mínimos quadrados generalizados (MQG).

Nos casos onde o amostrador por importância é da família exponencial, a versão correspondente à equação (22) passa a ser linear em a . Impondo ainda a hipótese de que os pesos $\omega(\cdot)$ sejam praticamente constantes, as regressões por MQG podem ser substituídas por regressões estimadas por mínimos quadrados ordinários (MQO), simplificando ainda mais o procedimento de minimização (MOURA, 2010).

O algoritmo de EIS a ser utilizado neste trabalho será um pouco mais geral do que o descrito acima, dado que o problema (12) envolve a avaliação de uma integral com dimensão mais alta. Para este caso, (20) precisa ser substituído por uma sequência de problemas de otimização de menor dimensão, o que é feito fatorando a densidade alvo em uma sequência de densidades condicionais. Este método é chamado de *amostragem por importância eficiente sequencial* (RICHARD; ZHANG, 2007) e será apresentado em versões posteriores do projeto.

Utilizar EIS em um contexto onde as densidades são da família exponencial permite aproximar a estimação de uma integral de grande dimensão em uma sequência de regressões estimadas por mínimos quadrados ordinários (MQO). Em particular, usando a conjugação entre a Wishart e a Normal no modelo de Philipov e Glickman (2006b), EIS pode ser usada para estimar o modelo de maneira mais eficiente. A estrutura de MSV Wishart pode ser incorporado em um modelo TVP-VAR, dando origem a um sistema que não apresentaria as mesmas deficiências dos modelos propostos em Cogley e Sargent (2005) e Primiceri (2005). Adicionalmente, pode-se utilizar o método de Rao-Blackwellização conforme proposto em Moura e Turatti (2014) para que a amostragem por importância eficiente seja combinada com o filtro de Kalman, tornando mais simples e eficiente o tratamento do modelo.

2 Objetivos do trabalho

O objetivo do trabalho que está sendo proposto é desenvolver métodos de inferência para o modelo TVP-VAR incorporando MSV à la Philipov e Glickman (2006b, 2006a). A metodologia a ser utilizada é a de amostragem por importância eficiente desenvolvida por Liesenfeld e Richard (2003) e Richard e Zhang (2007) combinada com Rao-Blackwellização proposta em Moura e Turatti (2014).

Especificamente, as etapas de trabalho são:

- a. Implementar estimativas de máxima verossimilhança, utilizando o algoritmo de EIS, no modelo de MSV proposto por Philipov e Glickman (2006b);
- b. Generalizar os métodos da etapa 1, combinando EIS com uma etapa de Rao-Blackwellização, para um modelo TVP-VAR com MSV Wishart e aproximar as estimativas (filtradas e suavizadas) para os estados latentes do modelo;

c. Desenvolver uma aplicação para o modelo utilizando dados da economia brasileira.

Os dados para a aplicação da etapa (c) ainda estão sendo levantados¹. A primeira ideia é utilizar o modelo proposto em (b) combinado com dados da renda de salários e agregados macroeconômicos para investigar a relação entre a política monetária e desigualdade de renda no país para os anos 2002-2015, similar ao trabalho desenvolvido por Mumtaz e Theophilopoulou (2017, 2015) para o Reino Unido.

Pretende-se trabalhar com o objetivo (a) durante o artigo para a disciplina de Econometria II e os dados da aplicação serão utilizados no artigo para a disciplina de Macroeconomia II, porém com uso do modelo TVP-VAR de Primiceri (2005).

Referências

ASAI, M.; MCALEER, M. The structure of dynamic correlations in multivariate stochastic volatility models. *Journal of Econometrics*, Elsevier, v. 150, n. 2, p. 182–192, 2009. Citado na página 4.

ASAI, M.; MCALEER, M.; YU, J. Multivariate stochastic volatility: a review. *Econometric Reviews*, Taylor & Francis, v. 25, n. 2-3, p. 145–175, 2006. Citado na página 4.

BAUMEISTER, C.; PEERSMAN, G. Time-varying effects of oil supply shocks on the us economy. *American Economic Journal: Macroeconomics*, American Economic Association, v. 5, n. 4, p. 1–28, 2013. Citado na página 2.

BOGNANNI, M. An Alternative Approach to VARs with Stochastic Volatility: Using Sequential Monte Carlo to Estimate the Discounted-Wishart Model. 2016. Disponível em: <<http://apps.olin.wustl.edu/conf/SBIES/Files/pdf/2016/189.pdf>>. Acesso em: 01-10-2017. Citado na página 5.

COGLEY, T.; SARGENT, T. J. Evolving Post-World War II U.S. Inflation Dynamics. *NBER Macroeconomics Annual*, v. 16, n. 1, p. 331–373, Jan 2001. Citado 2 vezes nas páginas 1 e 2.

COGLEY, T.; SARGENT, T. J. Drifts and volatilities: monetary policies and outcomes in the post wwii us. *Review of Economic dynamics*, Elsevier, v. 8, n. 2, p. 262–302, 2005. Citado 4 vezes nas páginas 2, 3, 4 e 8.

DEL NEGRO, M.; SCHORFHEIDE, F. Bayesian macroeconometrics. In: GEWEKE, J.; KOOP, G.; DIJK, H. V. (Ed.). *The Oxford Handbook of Bayesian Econometrics*. Oxford: Oxford University Press, 2013. cap. 7, p. 293–389. Citado na página 1.

DURBIN, J.; KOOPMAN, S. J. *Time series analysis by state space methods*. 2. ed. [S.l.]: Oxford University Press, 2012. Citado 2 vezes nas páginas 3 e 6.

¹ Como esta primeira apresentação é mais focada em tema e objetivos, deixei a aplicação de fora. Se der tempo na apresentação de terça-feira eu vou levar para conversar o que eu tenho e as dúvidas que tenho para ver se alguém tem sugestões sobre essa parte.

- GALÍ, J.; GAMBETTI, L. The effects of monetary policy on stock market bubbles: Some evidence. *American Economic Journal: Macroeconomics*, American Economic Association, v. 7, n. 1, p. 233–257, 2015. Citado na página 2.
- GEWEKE, J. Bayesian inference in econometric models using monte carlo integration. *Econometrica*, v. 57, n. 6, 1989. Citado na página 5.
- LIESENFELD, R.; RICHARD, J.-F. Univariate and multivariate stochastic volatility models: estimation and diagnostics. *Journal of empirical finance*, Elsevier, v. 10, n. 4, p. 505–531, 2003. Citado na página 8.
- LUCAS, R. E. Econometric policy evaluation: A critique. *Studies in Business Cycle Theory*, p. 104–130, 1976. Citado na página 1.
- MOURA, G. V. *Efficient importance sampling in applied econometrics*. Tese (Doutorado), 2010. Citado 3 vezes nas páginas 6, 7 e 8.
- MOURA, G. V.; TURATTI, D. E. Efficient estimation of conditionally linear and gaussian state space models. *Economics Letters*, Elsevier, v. 124, n. 3, p. 494–499, 2014. Citado 2 vezes nas páginas 5 e 8.
- MUMTAZ, H.; THEOPHILOPOULOU, A. *Monetary Policy and Inequality in the UK*. [S.l.], 2015. Citado na página 9.
- MUMTAZ, H.; THEOPHILOPOULOU, A. The impact of monetary policy on inequality in the uk. an empirical analysis. *European Economic Review*, Elsevier, v. 98, p. 410–423, 2017. Citado na página 9.
- MUMTAZ, H.; ZANETTI, F. Labor market dynamics: A time-varying analysis. *Oxford Bulletin of Economics and Statistics*, Wiley Online Library, v. 77, n. 3, p. 319–338, 2015. Citado na página 2.
- PHILIPPOV, A.; GLICKMAN, M. E. Factor multivariate stochastic volatility via wishart processes. *Econometric Reviews*, Taylor & Francis, v. 25, n. 2-3, p. 311–334, 2006. Citado 4 vezes nas páginas 1, 3, 4 e 8.
- PHILIPPOV, A.; GLICKMAN, M. E. Multivariate stochastic volatility via wishart processes. *Journal of Business & Economic Statistics*, Taylor & Francis, v. 24, n. 3, p. 313–328, 2006. Citado 4 vezes nas páginas 1, 3, 4 e 8.
- PRIMICERI, G. E. Time varying structural vector autoregressions and monetary policy. *The Review of Economic Studies*, Wiley-Blackwell, v. 72, n. 3, p. 821–852, 2005. Citado 4 vezes nas páginas 3, 4, 8 e 9.
- RICHARD, J.-F.; ZHANG, W. Efficient high-dimensional importance sampling. *Journal of Econometrics*, Elsevier, v. 141, n. 2, p. 1385–1411, 2007. Citado 2 vezes nas páginas 7 e 8.
- ROBERT, C. P.; CASELLA, G. *Monte Carlo statistical methods*. [S.l.]: Springer, 2010. Citado na página 6.
- SIMS, C. A. Comment on sargent and cogley’s “Evolving U.S. Postwar Inflation Dynamics”. In: *NBER Macroeconomics Annual*. [S.l.: s.n.], 2001. p. 273–278. Citado na página 2.
- STOCK, J. H. Evolving Post-World War II US Inflation Dynamics: Comment. *NBER macroeconomics annual*, MIT Press, v. 16, p. 379–387, 2001. Citado na página 2.